

Hito 1: Propuesta, Análisis y Baselines

Recomendación musical personalizada a partir de historiales de escucha de Last.fm

Agustin Llambias

Amaya Quero

Larry Uribe

1. Descripción del problema y justificación

Los servicios de música digital concentran catálogos muy grandes, por lo que un usuario puede tener dificultades para descubrir canciones o artistas alineados con sus gustos. En este contexto, un sistema recomendador permite ordenar el catálogo y sugerir ítems relevantes usando información histórica de interacciones. El proyecto se enfoca en recomendación musical personalizada usando registros de escucha como retroalimentación implícita: si un usuario escuchó una canción, se asume una señal positiva de interés, aunque no exista una calificación explícita.

El problema principal es: dado el historial de escucha de un usuario, recomendar canciones o artistas que el usuario no haya escuchado previamente y que tengan alta probabilidad de ser relevantes para él. Este caso es representativo de sistemas recomendadores reales porque trabaja con feedback implícito, alta cardinalidad de ítems, sesgos de popularidad y posibles cambios temporales en las preferencias.

El dataset utilizado es *Last.FM_dataset* de Kaggle, disponible en <https://www.kaggle.com/datasets/harshal19t/lastfm-dataset>. En la versión descargada se observan 166.153 registros de escucha, donde cada registro indica usuario, artista, canción, álbum, fecha y hora. Dado que no existen ratings explícitos, cada escucha se interpreta como feedback implícito positivo.

2. Objetivos del proyecto

El objetivo general es construir y evaluar un sistema de recomendación musical personalizada sobre datos de Last.fm, comparando baselines simples con métodos más expresivos bajo un protocolo reproducible de evaluación offline.

Los objetivos específicos son:

- Caracterizar el dataset mediante análisis descriptivo de usuarios, artistas, canciones, álbumes e interacciones.
- Definir un protocolo de train/test para evaluar recomendación top-N con datos implícitos.
- Implementar al menos tres modelos de referencia: Random, Most Popular y un modelo específico al dominio musical.
- Comparar los modelos usando métricas de ranking como HitRate@10, Precision@10, MAP@10 y nDCG@10.
- Desarrollar en Midterm un método más avanzado, como filtrado colaborativo item-item, factorización matricial para feedback implícito o un enfoque híbrido.

3. Análisis descriptivo de los datos

Se define cada ítem como el par artista-canción, con el fin de distinguir canciones con el mismo nombre interpretadas por artistas distintos. La Tabla 1 resume las estadísticas principales del dataset.

La matriz usuario-ítem tiene densidad aproximada de 15,89 %. Aunque este valor no es extremadamente disperso, el catálogo sigue siendo amplio en relación con el número de usuarios. La distribución de interacciones por usuario es desbalanceada: el usuario con menos registros tiene 1.063 escuchas, mientras que el máximo alcanza 33.695. A nivel de ítems existe una cola larga: la mayoría de canciones aparece una o dos veces, mientras que unos pocos ítems concentran muchas escuchas.

Los artistas más escuchados incluyen Sophie, Madlib, Bicep, Taylor Swift y Arlo Parks. Entre los ítems más frecuentes aparecen *Metric - Cascades (Dirt Road Version)* y *Ocean Waves For Sleep - Rolling Ocean Waves*. Estos patrones justifican incluir un baseline de popularidad y, al mismo tiempo, evaluar métodos personalizados que no se limiten a recomendar solamente los ítems globalmente dominantes.

Métrica	Valor	Métrica	Valor
Registros	166.153	Usuarios	11
Artistas	22.823	Ítems artista-canción	76.038
Tracks por nombre	67.241	Álbumes	38.629
Duplicados exactos	0	Álbumes faltantes	12
Rango temporal	01-01-2021 a 31-01-2021		
Sparsity usuario-ítem	0,8411		

Cuadro 1: Resumen descriptivo del dataset Last.fm descargado desde Kaggle.




Figura 1: Distribución de escuchas por usuario y artistas más frecuentes en el dataset.




Figura 2: Distribución de popularidad de ítems en escala log-log. La forma de cola larga muestra que pocos ítems concentran muchas escuchas, mientras que la mayoría aparece pocas veces.

4. Baselines y protocolo experimental

La evaluación usa split temporal por usuario: el 80 % inicial de sus escuchas queda en train y el 20 % final en test. Los ítems relevantes son canciones futuras que el usuario no había escuchado en train. Esta decisión evita filtración de información futura hacia el entrenamiento y se ajusta mejor a un escenario real de recomendación musical que un split aleatorio.

Se implementaron tres modelos de referencia:

- **Random:** recomienda canciones aleatorias no vistas por el usuario. Sirve como control mínimo para verificar el protocolo.
- **Most Popular:** recomienda las canciones más frecuentes en train. No es personalizado, pero captura el sesgo global de popularidad.

- **Favorite Artist Popular:** identifica los artistas más escuchados por cada usuario en train y recomienda canciones populares de esos artistas que el usuario aún no haya escuchado.

Las métricas utilizadas son HitRate@10, Precision@10, MAP@10 y nDCG@10. HitRate@10 mide si existe al menos un acierto en el top 10; Precision@10 mide la proporción de recomendaciones relevantes; MAP@10 considera la posición de los aciertos; y nDCG@10 premia que los ítems relevantes aparezcan más arriba en el ranking.

Modelo	HitRate@10	Precision@10	MAP@10	nDCG@10
Random	0,3636	0,0364	0,0074	0,0310
Most Popular	0,0909	0,0455	0,0202	0,0367
Favorite Artist Popular	0,4545	0,0455	0,0133	0,0459

Cuadro 2: Resultados preliminares de baselines con split temporal por usuario.

El baseline personalizado por artista obtiene el mayor HitRate@10 y nDCG@10, lo que sugiere que la afinidad histórica usuario-artista aporta una señal personalizada útil. Most Popular logra el mejor MAP@10, mostrando que la popularidad global sigue siendo competitiva para ordenar algunos aciertos tempranos.

Estos resultados deben interpretarse con cautela. Random obtiene un HitRate@10 relativamente alto porque cada usuario conserva, en promedio, 2.291 ítems relevantes futuros bajo el split temporal. Por lo tanto, HitRate@10 es poco exigente en este primer experimento y debe complementarse con Precision@10, MAP@10 y nDCG@10. Para Midterm se propone evaluar también con negative sampling o con un test set más restringido por usuario.

El código que respalda la carga de datos, el análisis descriptivo, las figuras y los baselines se encuentra en el notebook `Hito_1_LastFM.ipynb` y en el script reproducible `hito1_lastfm_baselines.py`.




Figura 3: Comparación visual de las métricas top-10 para los tres baselines implementados.

5. Planificación para Midterm

Los criterios de éxito para Midterm serán superar Most Popular en al menos una métrica de ranking top-K, mantener cobertura razonable de usuarios e ítems, reportar tiempos de ejecución y dejar el pipeline documentado para reproducir resultados.

6. Limitaciones y riesgos

La principal limitación del dataset descargado es el bajo número de usuarios: existen solo 11 usuarios, aunque cada uno tiene muchas interacciones. Esto permite estudiar personalización a nivel individual, pero limita la generalización estadística de resultados agregados. Para mitigar este problema, en Midterm se reportarán métricas por usuario y se analizará la sensibilidad al protocolo de evaluación.

Fecha	Actividad	Resultado esperado
08/05	Cierre Hito 1	Propuesta, EDA y baselines iniciales documentados.
09/05–16/05	Limpieza y normalización	Pipeline reproducible y matriz usuario-ítem.
17/05–24/05	Filtrado colaborativo	Modelos user-user e item-item con distintas similitudes.
25/05–31/05	Método avanzado	Factorización matricial para feedback implícito o método híbrido.
01/06–04/06	Evaluación y análisis	Tabla comparativa, análisis de errores y limitaciones.
05/06	Entrega Midterm	Informe intermedio con resultados preliminares.

Cuadro 3: Plan de trabajo propuesto para el Hito 2.

Otra limitación es que el dataset no incluye ratings explícitos ni información semántica rica como géneros o tags. Para este hito se trabajó con feedback implícito y metadatos básicos. En la siguiente etapa se evaluará si conviene enriquecer el dataset o concentrarse en métodos colaborativos que exploten mejor la matriz de escuchas.

7. Bibliografía

- Harshalsps19t. *Last.FM_ dataset*. Kaggle, 2023. <https://www.kaggle.com/datasets/harshal19t/lastfm-dataset>
- Sgardelis, K., Margaris, D., Spiliotopoulos, D. y Vassilakis, C. *An evaluation review of user similarity metrics in sparse collaborative filtering datasets*. International Journal of Data Science and Analytics, 2025.
- Koren, Y., Bell, R. y Volinsky, C. *Matrix factorization techniques for recommender systems*. Computer, 42(8), 30–37, 2009.
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y. y Wang, M. *LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation*. SIGIR, 2020.