

Hito 1: Propuesta, Análisis y Baselines

Recomendación musical personalizada usando playlists de Spotify

Agustin Llambias Amaya Quero Larry Uribe

Repositorio: <https://github.com/mayafzt/Proyecto-RecSys-2026-1>

1. Descripción del problema y justificación

Los servicios de música digital concentran catálogos muy grandes, por lo que un usuario puede tener dificultades para descubrir canciones alineadas con sus gustos o con el contexto de escucha que desea. En este proyecto se aborda un problema de recomendación musical personalizada a partir de playlists: dado un conjunto de canciones ya presentes en una playlist, recomendar canciones candidatas que podrían completar o enriquecer esa playlist.

El problema es relevante porque las playlists expresan preferencias musicales, contexto de uso y señales curatoriales de los usuarios. A diferencia de un sistema basado en ratings explícitos, este caso utiliza feedback implícito: si una canción aparece en una playlist de un usuario, se interpreta como una señal positiva de afinidad. Esto permite formular el problema como recomendación top-N de canciones usando interacciones usuario-playlist-canción.

El dataset utilizado es *Spotify Playlists* de Kaggle, disponible en <https://www.kaggle.com/datasets/andrewmvd/spotify-playlists>. El archivo local utilizado es `data/spotify_dataset.csv`, con columnas `user_id`, `artistname`, `trackname` y `playlistname`. Cada registro indica que una canción de un artista aparece en una playlist asociada a un usuario.

2. Objetivos del proyecto

El objetivo general es construir y evaluar un sistema de recomendación musical para completar playlists de Spotify, comparando baselines simples con métodos personalizados bajo un protocolo reproducible de evaluación offline.

Los objetivos específicos son:

- Caracterizar el dataset mediante análisis descriptivo de usuarios, artistas, canciones, playlists e interacciones.
- Definir un protocolo de train/test para evaluar recomendación top-N a nivel de playlist.
- Implementar al menos tres modelos de referencia: Random, Most Popular y un modelo específico al dominio de playlists.
- Comparar los modelos usando métricas de ranking como HitRate@10, Precision@10, MAP@10 y nDCG@10.
- Desarrollar en Midterm un método más avanzado, como filtrado colaborativo item-item, factorización matricial implícita o un enfoque híbrido basado en texto de playlists y co-ocurrencia de canciones.

3. Análisis descriptivo de los datos

El archivo completo contiene 12.199.339 registros válidos, 15.889 usuarios, 271.369 artistas, 1.854.175 nombres de tracks, 2.614.129 ítems únicos definidos como par artista-canción y 225.591 playlists usuario-nombre.

Métrica	Valor	Métrica	Valor
Registros	12.199.339	Usuarios	15.889
Artistas	271.369	Ítems artista-canción	2.614.129
Tracks por nombre	1.854.175	Playlists	225.591

Cuadro 1: Resumen global del dataset Spotify Playlists.

Para este Hito 1 se trabajó con una muestra determinística del 30 % de las playlists, preservando playlists completas mediante hashing de `user_id` y `playlistname`. Esta decisión se justifica porque el CSV pesa aproximadamente 1,18 GB y el objetivo de la primera entrega es exploratorio: entender los datos, validar un protocolo de evaluación e

implementar baselines. La muestra mantiene reproducibilidad y escala suficiente para observar patrones robustos. En etapas posteriores se podrá escalar el pipeline al dataset completo o a muestras estratificadas adicionales.

Para procesar el archivo se utilizó DuckDB en vez de cargar el CSV completo directamente con pandas. La razón es metodológica y computacional: DuckDB es una base de datos analítica embebida diseñada para ejecutar consultas SQL dentro del proceso de análisis, con ejecución eficiente sobre archivos locales y soporte nativo para lectura de CSV. Esto permitió calcular estadísticas globales del archivo completo y construir la muestra reproducible sin materializar inicialmente los 12,2 millones de filas como un único DataFrame en memoria. Luego, una vez reducida la escala mediante la muestra del 30 %, se usó pandas para los baselines y visualizaciones.

La muestra contiene 3.721.218 registros, 12.745 usuarios, 150.326 artistas, 947.293 tracks, 1.273.839 ítems artista-canción y 68.012 playlists. La mediana de canciones por playlist es 11 y el promedio es 54,71, lo que evidencia alta variabilidad en el tamaño de playlists.




Figura 1: Distribución de tamaño de playlists y artistas más frecuentes en la muestra del 30 %.




Figura 2: Distribución de popularidad de canciones en escala log-log. La cola larga indica que pocas canciones concentran muchas apariciones, mientras que la mayoría aparece pocas veces.

4. Baselines y protocolo experimental

La evaluación usa un esquema *leave-last-out* por playlist. Para cada playlist con al menos tres canciones, se oculta la última canción como ítem de test y se usan las canciones previas como contexto de entrenamiento. El modelo debe recomendar un ranking top-10 de canciones candidatas no vistas en esa playlist.

Se evaluaron 63.851 playlists de la muestra, con un catálogo de entrenamiento de 1.258.737 ítems. Se implementaron tres baselines:

- **Random:** recomienda canciones aleatorias no presentes en la playlist. Sirve como control mínimo.
- **Most Popular:** recomienda las canciones más frecuentes del conjunto de entrenamiento, excluyendo las ya presentes en la playlist.
- **Playlist Name Popular:** usa tokens del nombre de la playlist para recomendar canciones populares en playlists con nombres similares. Es específico al problema, porque explota información contextual de playlists.

Las métricas utilizadas son HitRate@10, Precision@10, MAP@10 y nDCG@10. HitRate@10 mide si existe al menos un acierto en el top 10; Precision@10 mide la proporción de recomendaciones relevantes; MAP@10 considera la posición del acierto; y nDCG@10 premia que el ítem relevante aparezca más arriba en el ranking.

Modelo	HitRate@10	Precision@10	MAP@10	nDCG@10
Random	0,0000	0,0000	0,0000	0,0000
Most Popular	0,0011	0,0001	0,0001	0,0004
Playlist Name Popular	0,0119	0,0012	0,0041	0,0058

Cuadro 2: Resultados preliminares de baselines sobre la muestra determinística del 30 %.

Los resultados muestran que el baseline basado en nombre de playlist supera a Random y Most Popular en todas las métricas. Aunque los valores absolutos son bajos, esto es esperable por el tamaño del catálogo y por la dificultad del protocolo: se intenta predecir una canción específica entre más de un millón de candidatos. La mejora relativa indica que el texto de la playlist contiene señal útil para personalizar recomendaciones.




Figura 3: Comparación visual de métricas top-10 para los tres baselines.

El código que respalda la carga de datos, las figuras y los baselines se encuentra en `hito1_spotify_baselines.py`. Los resultados tabulares se exportan en `resultados_hito1_spotify.csv` y `resultados_hito1_spotify.md`.

5. Planificación para Midterm

Fecha	Actividad	Resultado esperado
08/05	Cierre Hito 1	Propuesta, EDA y baselines iniciales documentados.
09/05–16/05	Limpieza y normalización	Pipeline reproducible, validación de muestra y preparación de matriz playlist-canción.
17/05–24/05	Filtrado colaborativo	Modelos item-item basados en co-ocurrencia de canciones en playlists.
25/05–31/05	Método avanzado	Factorización matricial implícita o modelo híbrido texto de playlist + co-ocurrencia.
01/06–04/06	Evaluación y análisis	Tabla comparativa, análisis de errores, cobertura y sensibilidad al tamaño de muestra.
05/06	Entrega Midterm	Informe intermedio con resultados preliminares.

Cuadro 3: Plan de trabajo propuesto para el Hito 2.

Los criterios de éxito para Midterm serán superar Most Popular en métricas de ranking top-K, mantener cobertura razonable de canciones, reportar tiempos de ejecución y dejar un pipeline documentado para reproducir resultados.

6. Limitaciones y riesgos

La principal limitación del Hito 1 es el uso de una muestra del 30 %. Esta muestra es suficientemente grande para análisis preliminar, pero no reemplaza una evaluación final sobre el dataset completo o sobre varias muestras. Para mitigar este riesgo, la muestra se construyó de manera determinística y preservando playlists completas. En Midterm se analizará la sensibilidad de resultados al tamaño de muestra.

Otra limitación es que el dataset no incluye audio features, géneros ni ratings explícitos. Por ello, los modelos iniciales dependen de popularidad, co-ocurrencia y texto de playlists. En la siguiente etapa se evaluarán métodos colaborativos más fuertes y posibles enriquecimientos de contenido si existe una fuente confiable para cruzar metadatos.

7. Uso de herramientas de IA

Durante el desarrollo del Hito 1 se utilizó asistencia de IA generativa como apoyo para estructurar el informe, revisar la consistencia entre el enunciado y los entregables, proponer redacción técnica, depurar código y verificar que los scripts fueran reproducibles. Las decisiones metodológicas, selección del dataset, interpretación de resultados y validación final fueron realizadas por el grupo.

En particular, la IA se empleó para: (i) transformar el análisis exploratorio y resultados preliminares en un formato de informe LaTeX; (ii) revisar que el informe cubriera los puntos solicitados para Hito 1; (iii) sugerir una justificación técnica para usar DuckDB y una muestra determinística del 30 %; y (iv) apoyar la revisión de código para generar métricas, figuras y archivos de resultados. Las conversaciones utilizadas como apoyo serán compartidas junto con la entrega, según corresponda.

Los principales prompts y conversaciones compartidas fueron:

- Revisión del enunciado y checklist del Hito 1: <https://chatgpt.com/share/69fe7497-b264-83e9-af99-d39056a4bdc1>
- Actualización al dataset definitivo Spotify Playlists: <https://chatgpt.com/share/69fe757d-a82c-83e9-ba6e-c106809575d2>
- Procesamiento eficiente del CSV grande y justificación de muestra: <https://chatgpt.com/share/69fe74e5-c4d0-83e9-911f-0ecdadd7898>
- Implementación y verificación de baselines: <https://chatgpt.com/share/69fe7523-8ac0-83e9-a7c6-0a46f9c092a0>
- Generación de figuras para el análisis descriptivo y resultados: <https://chatgpt.com/share/69fe74e5-c4d0-83e9-911f-0ecdadd7898>

8. Bibliografía

- Andrew Mvd. *Spotify Playlists*. Kaggle. <https://www.kaggle.com/datasets/andrewmvd/spotify-playlists>
- Raasveldt, M. y Mühleisen, H. *DuckDB: An Embeddable Analytical Database*. CIDR, 2020. <https://duckdb.org/library/duckdb/>
- DuckDB Documentation. *CSV Import*. <https://duckdb.org/docs/stable/data/csv/overview>
- Koren, Y., Bell, R. y Volinsky, C. *Matrix factorization techniques for recommender systems*. Computer, 42(8), 30–37, 2009.
- Ricci, F., Rokach, L. y Shapira, B. *Recommender Systems Handbook*. Springer, 2015.
- He, X., Deng, K., Wang, X., Li, Y., Zhang, Y. y Wang, M. *LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation*. SIGIR, 2020.